

Laporan Teknis Komprehensif KeduaKali: Coding Camp 2026 powered by DBS Foundation

ID Tim Capstone Project : CC26-PSU226

Tema Capstone : *Sustainable & Responsible Consumption*

Nama/Judul Proyek : KeduaKali — *Platform Cerdas Penyelamat Makanan Leftover*

Anggota Tim:

ID Anggota	Nama & Peran
CACC319D6X0702	Cantyka Laily Sabila — AI Engineer
CACC319D6Y0793	Farhan Ar Rahman — AI Engineer
CDCC319D6X2692	Alissya Humairah Martiasaputri — Data Science
CDCC319D6X2689	Chyntia Claudia — Data Science
CFCC319D6Y0784	Abrar Naufal Fadhilah Cut — Full-Stack Web Developer
CFCC183D6X1305	Sabrina Filda Fannisda — Full-Stack Web Developer

BAB 1: PROBLEM DISCOVERY

1.1 Latar Belakang dan Konteks Masalah

Setiap tahun, jutaan ton makanan terbuang secara sia-sia di seluruh dunia. Masalah limbah makanan bukan sekadar isu lingkungan, melainkan juga krisis ekonomi yang nyata. Di Indonesia, kondisi ini jauh lebih mengkhawatirkan karena tingginya volatilitas dan kurangnya infrastruktur pemantauan yang memadai. Proyek KeduaKali dibangun berdasarkan urgensi untuk menangani masalah tersebut secara sistematis dan berbasis data. Platform ini dirancang sebagai penghubung cerdas yang menyalurkan makanan sisa dari restoran kepada

konsumen yang tepat, pada waktu yang tepat, serta dengan harga yang sesuai.

1.2 Identifikasi Masalah Bisnis

Berdasarkan analisis awal, terdapat tujuh pertanyaan bisnis yang menjadi landasan investigasi data dalam proyek ini:

No	Pertanyaan Bisnis	Dataset Terkait
1	Perbandingan estimasi kerugian ekonomi (economic loss) akibat food waste pada berbagai kategori produk di tingkat global dari tahun 2018–2024	global_food_wastage
2	Tren volume surplus makanan pada kategori Prepared Food di Indonesia dibandingkan negara lain (2018–2024)	global_food_wastage
3	Tren kerugian ekonomi akibat limbah makanan di Indonesia pada kategori Prepared Food dari tahun 2018–2024	global_food_wastage
4	Perbandingan quantity_sold pada berbagai tipe restoran selama Jan 2024 – Jan 2025 untuk identifikasi potensi surplus tertinggi	restaurant_sales
5	Pengaruh kondisi cuaca terhadap quantity_sold pada berbagai tipe restoran (Jan 2024 – Jan 2025)	restaurant_sales
6	Pengaruh rasio Quantity of Food / Number of Guests terhadap tingkat food waste dan efisiensi produksi	food_wastage
7	Efektivitas pemberian promo (has_promotion) dalam meningkatkan quantity_sold pada menu berpotensi limbah	restaurant_sales

1.3 Tujuan Proyek

- Memahami skala dan pola limbah makanan secara global, khususnya di

wilayah Indonesia.

- Memetakan perilaku operasional restoran kaitannya dengan potensi surplus makanan.
- Membuktikan secara statistik efektivitas mekanisme promosi dalam menekan volume limbah makanan.
- Memberikan rekomendasi berbasis data untuk pengembangan fungsionalitas platform KeduaKali.

BAB 2: DATASET DAN DATA WRANGLING

2.1 Sumber Data

Proyek ini memanfaatkan tiga dataset yang dihimpun dari sumber publik dan dikelola melalui Google Drive. Setiap dataset memiliki peranan spesifik dan saling melengkapi guna menjawab rumusan pertanyaan bisnis.

- **restaurant_sales_data:** Terdiri dari 10.000 baris dan 13 kolom. Dataset ini berisi data transaksional harian restoran, mencakup tanggal, tipe restoran, nama menu, tipe sajian, biaya bahan, harga pasar, harga jual aktual, unit terjual, status promo, event khusus, dan kondisi cuaca. Dataset ini digunakan untuk menjawab Pertanyaan Bisnis 4, 5, dan 7.
- **global_food_wastage_dataset:** Terdiri dari 5.000 baris dan 8 kolom. Berisi statistik limbah makanan tingkat negara periode 2018 hingga 2024, yang mencakup total limbah dalam ton, kerugian ekonomi dalam juta USD, rata-rata limbah per kapita, populasi, serta persentase limbah rumah tangga. Dataset ini digunakan untuk menjawab Pertanyaan Bisnis 1, 2, dan 3.
- **food_wastage_data:** Terdiri dari 1.782 baris dan 11 kolom. Berisi data operasional limbah makanan per acara, mencakup jenis makanan, jumlah tamu, tipe acara, kuantitas makanan, kondisi penyimpanan, dan jumlah makanan yang terbuang. Dataset ini digunakan untuk menjawab Pertanyaan Bisnis 6.

2.2 Data Assessment

Evaluasi kualitas awal pada ketiga dataset mengungkap isu-isu berikut yang perlu ditangani sebelum analisis:

Dataset	Isu Ditemukan	Rencana Penanganan
food_wastage_data	164 baris duplikat ditemukan. Tidak ada missing value.	Hapus duplikat. Buat kolom Timestamp sintetis untuk analisis temporal.
global_food_wastage_dataset	Tidak ada missing value maupun duplikat. Kolom year masih bertipe int64.	Konversi year ke datetime. Ubah country dan food_category ke tipe category.
restaurant_sales_data	Tidak ada missing value maupun duplikat. Kolom date bertipe object.	Konversi date ke datetime. Ubah kolom kategorikal ke tipe category.

2.3 Data Cleaning

2.3.1 Cleaning food_wastage_data

Dataset ini memiliki 164 baris duplikat yang dihapus menggunakan `drop_duplicates()`. Karena dataset aslinya tidak memiliki dimensi waktu, dibuat kolom Timestamp sintetis menggunakan `np.linspace` untuk mendistribusikan seluruh entri secara merata sepanjang Januari 2024 hingga Januari 2025.

Keputusan ini merupakan rekayasa yang disengaja untuk memungkinkan analisis temporal, bukan manipulasi data. Dari Timestamp tersebut, diekstrak fitur-fitur seperti Year, Month, DayOfWeek, IsWeekend, dan Quarter yang dibutuhkan model.

Selain itu, dibuat fitur `food_per_guest_ratio` dengan rumus:

$$\text{food_per_guest_ratio} = \text{Quantity of Food} \div \text{Number of Guests}$$

Fitur ini menjadi metrik efisiensi produksi yang objektif dan comparable antar jenis acara.

Deteksi outlier dilakukan secara visual melalui boxplot. Ditemukan bahwa Wastage Food Amount dan food_per_guest_ratio memiliki nilai ekstrim yang menonjol. Penanganan outlier dilakukan dengan metode IQR:

Kolom	Batas Bawah	Batas Atas
Wastage Food Amount	Dihitung dari $Q1 - 1.5 * IQR$	Dihitung dari $Q3 + 1.5 * IQR$
food_per_guest_ratio	Dihitung dari $Q1 - 1.5 * IQR$	Dihitung dari $Q3 + 1.5 * IQR$

Setelah filtering, data berkurang dari 1.618 baris (setelah hapus duplikat) menjadi sekitar 1.400 baris bersih. Boxplot perbandingan Before vs After mengkonfirmasi distribusi yang jauh lebih rapat dan terkontrol.

Standardisasi menggunakan StandardScaler diterapkan pada seluruh fitur numerik, menghasilkan mean mendekati 0.0 dan std tepat 1.0 untuk semua kolom. Encoding dilakukan dengan dua strategi: Ordinal Encoding untuk kolom Pricing (Low=0, Moderate=1, High=2) dan Label Encoding untuk kolom kategorikal lainnya.

2.3.2 Cleaning global_food_wastage_dataset

Dataset ini adalah yang paling bersih di antara ketiganya. Tidak ada missing value maupun duplikat. Fokus cleaning hanya pada konversi tipe data: kolom Year dikonversi ke datetime, serta Country dan Food Category diubah ke tipe category.

Boxplot mengkonfirmasi tidak ada outlier pada semua fitur numerik. Distribusi uniform yang sangat merata mengindikasikan data dikumpulkan secara proporsional lintas negara dan tahun. Standardisasi menggunakan StandardScaler berhasil sempurna dengan bentuk kurva KDE yang identik sebelum dan sesudah scaling.

2.3.3 Cleaning restaurant_sales_data

Dataset ini terdiri dari 10.000 entri tanpa missing value maupun duplikat. Cleaning berfokus pada konversi date dari object ke datetime, serta mengubah kolom restaurant_type, meal_type, dan weather_condition ke tipe category untuk efisiensi memori.

Setelah proses cleaning, dibuat kolom tambahan leftover yang merepresentasikan estimasi sisa makanan per transaksi, yang kemudian digunakan sebagai target metrik dalam A/B Testing.

BAB 3: EXPLORATORY DATA ANALYSIS (EDA)

3.1 Kerugian Ekonomi Global per Kategori Makanan

Analisis dilakukan terhadap total kerugian ekonomi (Economic Loss) seluruh kategori makanan secara global dari 2018 hingga 2024.

Temuan Utama: Prepared Food Mendominasi Kerugian Ekonomi Global

- Total kerugian ekonomi kategori Prepared Food mencapai 17,87 juta USD (2018–2024), melampaui semua kategori lain termasuk Meat & Seafood.
- Fokus KeduaKali pada segmen Prepared Food bukan hanya logis secara operasional, tetapi juga optimal secara dampak bisnis.
- Kategori dengan kerugian terendah adalah Grains & Pulses, menunjukkan ketahanan penyimpanan yang lebih baik dibanding produk siap saji.

3.2 Tren Surplus Makanan Siap Saji di Indonesia

Perbandingan volume surplus makanan siap saji antara Indonesia dan negara-negara lain memperlihatkan pola yang mengkhawatirkan.

Temuan Utama: Indonesia Mengalami Lonjakan Surplus 380% dalam Satu Tahun

- Volume surplus Prepared Food di Indonesia melonjak drastis sebesar 380% hanya dalam satu tahun: dari 46.608 ton (2022) menjadi 224.157 ton (2023).
- Dibandingkan dengan Meksiko sebagai pembanding, Indonesia menunjukkan volatilitas yang jauh lebih ekstrem.
- Data tahun 2024 tidak tersedia, mengindikasikan absennya infrastruktur monitoring food waste yang memadai di Indonesia.
- Indonesia menempati posisi keempat global dalam rasio limbah per populasi, sebuah sinyal krisis yang mendesak.

3.3 Tren Kerugian Ekonomi Limbah Makanan di Indonesia

Kerugian ekonomi di Indonesia berfluktuasi selaras dengan volume limbahnya. Setelah mencapai titik terendah pada tahun 2019 dan 2022 (berkisar di angka 44 juta USD), kerugian mencapai puncaknya pada tahun 2023 sebesar 201,9 juta USD. Tanpa intervensi, risiko akan terus berlanjut di tingkat yang kritis.

3.4 Analisis Potensi Surplus Berdasarkan Tipe Restoran

Setiap tipe restoran memiliki periode kerentanan surplus yang unik berdasarkan volume penjualannya:

- **Fine Dining:** Paling kritis pada bulan Agustus 2024 dengan volume terendah 220,98 unit.
- **Cafe:** Surplus muncul lebih awal, yakni pada April 2024 (233,47 unit).
- **Kopitiam:** Penjualan turun drastis pada Juli 2024 (236 unit).
- **Food Stall:** Tetap paling stabil, dengan titik terendah di bulan Juli 2024 (264,47 unit).
- **Casual Dining:** Surplus terjadi paling lambat pada September 2024 (267,78 unit).

Insight Strategis: Pola Penjualan Agregat

- Penjualan terendah secara agregat terjadi pada Juli 2024 (1.282 unit) — periode risiko limbah tertinggi secara nasional.
- Puncak penjualan tertinggi terjadi pada Januari 2024 (1.489 unit), kembali menguat di Agustus dan November.
- Setiap tipe bisnis memiliki 'musim surplus' yang berbeda — pendekatan one-size-fits-all tidak akan efektif.

3.5 Pengaruh Cuaca terhadap Penjualan

Kondisi cuaca terbukti memiliki pengaruh langsung terhadap penjualan dan potensi limbah.

- **Kopitiam** mengalami penjualan terendah saat cuaca cerah, menjadikannya

rentan surplus.

- **Food Stall** menghadapi penurunan drastis saat hujan, sehingga menjadi prioritas penyelamatan makanan pada kondisi tersebut.
- **Casual Dining** terbukti paling tangguh terhadap perubahan cuaca.

Tipe Restoran	Kondisi Tertinggi	Kondisi Terendah (Surplus Risk)
Kopitiam	Hujan (327,38 unit)	Cerah (292,76 unit)
Food Stall	Cerah (292,46 unit)	Hujan (247,15 unit)
Fine Dining	Beragam (233–248 unit)	Berawan (233,17 unit)
Cafe	Hujan (281,66 unit)	Berawan (253,02 unit)
Casual Dining	Stabil di semua cuaca	Rentang 295–298 unit (paling resilien)



Insight Strategis: Cuaca sebagai Trigger Real-Time

- Food Stall adalah prioritas penyelamatan saat Hujan — penjualan turun drastis sedangkan produksi tetap.
- Kopitiam adalah prioritas saat Cerah — pola berlawanan dengan Food Stall.
- Temuan ini membuktikan bahwa integrasi Weather API ke dalam mesin rekomendasi adalah keputusan berbasis data, bukan asumsi.
- Casual Dining dapat diabaikan sebagai trigger berbasis cuaca karena sangat resilien.

3.6 Pengaruh Rasio Porsi terhadap Limbah Makanan

Scatter plot dengan regression line antara food_per_guest_ratio dan Wastage Food Amount memperlihatkan pola yang fundamental.

 Temuan Utama: Efisiensi Skala vs Risiko Kelompok Kecil

- Tren regresi menunjukkan penurunan limbah saat rasio meningkat (mendekati 1,5) — acara besar menghasilkan efek crowd effect di mana konsumsi komunal lebih optimal.
- Sebaliknya, saat rasio porsi rendah (tamu sedikit), limbah memuncak di 35–40 kg per acara.
- Ketidakpastian prediksi tinggi: sebaran data yang lebar membuktikan manajemen manual tidak mampu memprediksi limbah secara akurat.
- Implikasi produk: untuk acara besar → tawarkan bundle; untuk acara kecil/harian → gunakan Content-Based Filtering untuk porsi individu.

3.7 Efektivitas Promosi dalam Menekan Limbah

Analisis bar chart perbandingan Ada Promo vs Tanpa Promo pada dua metrik (quantity_sold dan leftover) menghasilkan temuan yang sangat signifikan.

Tipe Restoran	Penjualan Tanpa Promo	Penjualan Ada Promo
Kopitiam	282,1 unit	461,8 unit (+63,6%)
Fine Dining	226,0 unit	309,2 unit (+36,8%)
Food Stall	Baseline	Peningkatan signifikan
Cafe	Baseline	Peningkatan konsisten
Casual Dining	Baseline	Peningkatan konsisten

Tipe Restoran	Sisa Tanpa Promo	Sisa Ada Promo
Kopitiam	69,0 kg	6,4 kg (↓3 90%)
Food Stall	79,1 kg	32,4 kg (↓3 59%)

Fine Dining	94,3 kg	65,5 kg (↓3 31%)
Cafe	Relatif tinggi	Turun konsisten
Casual Dining	Stabil	Turun moderat

Implementasi promosi terbukti secara deskriptif dalam meningkatkan penjualan dan mengurangi sisa makanan. Sebagai contoh, restoran tipe Kopitiam mencatat peningkatan penjualan sebesar 63,6% dan penurunan sisa makanan hingga 90% (dari 69,0 kg menjadi 6,4 kg) dengan adanya promosi.

BAB 4: PENGUJIAN A/B UNTUK VALIDASI EFEKTIVITAS PROMOSI

4.1 Latar Belakang & Tujuan

Temuan EDA pada Pertanyaan 7 menunjukkan indikasi kuat bahwa promosi efektif dalam meningkatkan penjualan dan menekan sisa makanan. Namun, temuan deskriptif saja tidak cukup untuk menjadi dasar keputusan bisnis. Diperlukan validasi statistik formal melalui A/B Testing.

Dataset yang digunakan adalah `restaurant_sales_cleaned.csv` yang berisi 8.583 transaksi restoran hasil proses cleaning dan label encoding. Semua kolom sudah dalam format numerik.

4.2 Desain Eksperimen

Analisis ini menggunakan 8.583 data transaksi bersih untuk memvalidasi efektivitas promosi secara formal. Pengujian dibagi menjadi dua kelompok:

- **Grup A (Kontrol):** Sekitar 7.401 transaksi yang dilakukan tanpa promosi (`has_promotion == 0`)
- **Grup B (Perlakuan):** Sekitar 1.182 transaksi yang melibatkan penggunaan promosi (`has_promotion == 1`).

Eksperimen menggunakan Uji-Z untuk proporsi (Tingkat Kepercayaan 95%), dengan metrik dikonversi ke format biner menggunakan nilai median sebagai ambang batas.

4.2.2 Hipotesis

Dua hipotesis diuji secara terpisah:

1. Uji 1 — Konversi Penjualan (quantity_sold)

- H_0 : Tidak ada perbedaan tingkat konversi penjualan antara Grup A dan Grup B ($p_A = p_B$)
- H_1 : Ada perbedaan tingkat konversi penjualan antara Grup A dan Grup B ($p_A \neq p_B$)

2. Uji 2 — Efisiensi Waste (leftover)

- H_0 : Tidak ada perbedaan tingkat efisiensi sisa makanan antara Grup A dan Grup B ($p_A = p_B$)
- H_1 : Ada perbedaan tingkat efisiensi sisa makanan antara Grup A dan Grup B ($p_A \neq p_B$)

4.2.3 Parameter Statistik

Parameter	Nilai
Alpha (α)	0,05
Confidence Level	95%
Jenis Uji	Two-sided test
Metode Utama	Z-Test untuk Proporsi (proportions_ztest dari statsmodels)
Threshold Metrik	Nilai median sebagai batas biner (lebih robust dari mean terhadap outlier)

4.3 Assumption Checking

Sebelum menjalankan Z-Test, dilakukan dua uji asumsi untuk mendokumentasikan karakteristik distribusi data:

- **Shapiro-Wilk Test:** Menguji normalitas distribusi data. Dengan $n > 8.000$, hampir pasti menolak normalitas, ini adalah ekspektasi pada sampel besar, bukan masalah. Z-Test tetap valid karena dijustifikasi oleh Central Limit Theorem (CLT).

- **Levene's Test:** Menguji homogenitas varians antar grup. Hasilnya menunjukkan varians kedua grup tidak homogen, yang dikonfirmasi sebagai informasi tambahan tanpa membatalkan metode yang dipilih.

Transparansi metodologi ini penting untuk integritas laporan ilmiah meskipun tidak mengubah pilihan metode.

4.4 Konversi Metrik ke Format Biner

Karena Z-Test proporsi membutuhkan data biner, variabel kontinu dikonversi menggunakan nilai median sebagai threshold:

- $\text{konversi_penjualan} = 1$ jika $\text{quantity_sold} > \text{median}(\text{quantity_sold})$, sebaliknya 0
- $\text{efisien_waste} = 1$ jika $\text{leftover} < \text{median}(\text{leftover})$, sebaliknya 0 — semakin rendah sisa = semakin efisien

4.5 Hasil Uji Statistik

4.5.1 Uji 1: Konversi Penjualan

Metrik	Grup A (Tanpa Promo)	Grup B (Ada Promo)
Rate Konversi	~0,49	~0,57
Z-Statistik	Jatuh di luar area kritis ($\pm 1,96$)	—
P-Value	< 0,05	—
Keputusan	TOLAK H_0 ✓	—
Cohen's d	Small effect	—

Kesimpulan: Terdapat perbedaan yang secara statistik signifikan dalam tingkat konversi penjualan antara transaksi dengan dan tanpa promosi. Promosi berpengaruh nyata terhadap peningkatan penjualan.

4.5.2 Uji 2: Efisiensi Waste

Metrik	Grup A (Tanpa Promo)	Grup B (Ada Promo)
Rate Efisiensi	~0,47	~0,56
Z-Statistik	Jatuh di luar area kritis ($\pm 1,96$)	—
P-Value	< 0,05	—
Keputusan	TOLAK H_0 ✓	—
Cohen's d	Small effect	—

Kesimpulan: Promosi tidak sekadar mendorong penjualan, tetapi juga secara statistik signifikan berdampak pada pengurangan sisa makanan. Ini selaras langsung dengan misi inti platform KeduaKali.

4.6 Catatan Penting: Statistical vs Practical Significance

Pada sampel besar ($n > 8.000$), hampir semua perbedaan sekecil apapun akan menghasilkan $p\text{-value} < 0.05$. Oleh karena itu, Cohen's d digunakan sebagai filter kedua untuk memastikan hasil signifikan secara statistik juga bermakna secara praktis.

Hasil Cohen's d menunjukkan small effect. Ini berarti meski promosi terbukti signifikan secara statistik, besarnya efek dalam konteks operasional perlu dikalibrasi lebih lanjut, terutama melalui analisis segmentasi per tipe restoran.

4.7 Analisis Segmentasi per Tipe Restoran

Analisis agregat dapat menyembunyikan perbedaan pola antar segmen. Oleh karena itu, Z-Test dijalankan secara terpisah untuk masing-masing dari 5 tipe restoran (tipe 0–4 hasil label encoding), dengan threshold median yang dihitung per tipe.



Hasil Segmentasi: Efek Promosi Tidak Seragam

1. Tipe dengan hasil signifikan + effect size besar: prioritas rollout promosi penuh.
2. Tipe dengan hasil signifikan + effect size kecil: efek nyata tapi kecil — perlu analisis cost-benefit sebelum rollout massal.

3. Tipe dengan hasil tidak signifikan: kemungkinan membutuhkan jenis promosi yang berbeda atau dipengaruhi faktor lain.
4. Tidak ada tipe yang dilewati karena kekurangan data (semua memenuhi minimum $n \geq 10$ per grup).

4.8 Keputusan Bisnis Berdasarkan Hasil A/B Testing

4.8.1 Implementasi Fitur Smart Promotion

Kedua hipotesis berhasil ditolak, memberikan justifikasi statistik yang kuat untuk meluncurkan fitur Smart Promotion sebagai fitur inti platform, bukan eksperimental. Sistem dapat menetapkan default-on untuk promosi pada slot makanan yang mendekati batas waktu (misalnya 2 jam sebelum tutup).

4.8.2 Integrasi ke Model Prediksi

1. **has_promotion** harus menjadi feature wajib dalam model prediksi leftover.
2. **Feature interaksi** $\text{has_promotion} \times \text{restaurant_type}$ diperlukan untuk menangkap efek heterogen antar segmen.
3. **Multi-armed bandit** sebagai evolusi dari A/B Testing statis ini untuk alokasi promo yang belajar secara real-time.

4.8.3 Catatan Metodologi & Limitasi

Aspek	Detail
Assumption Checking	Shapiro-Wilk & Levene dijalankan untuk transparansi, penolakan normalitas pada n besar adalah ekspektasi, bukan masalah.
Pemilihan Metode	Z-Test proporsi valid via CLT pada $n > 1.000$ di tiap grup.
Ukuran Sampel	Grup A: ~7.401 Grup B: ~1.182 , tidak seimbang, tapi Z-Test tetap valid.
Limitasi Utama	Tidak ada kolom waktu, yang berarti efek temporal dan novelty effect tidak bisa dikendalikan.
Saran Pengembangan	Untuk deployment produksi: pertimbangkan Bonferroni correction pada analisis segmentasi dan lakukan A/B Testing prospektif dengan randomisasi eksplisit.

BAB 5: KESIMPULAN DAN REKOMENDASI STRATEGIS

5.1 Kesimpulan Utama

Analisis dari tiga dataset, tujuh pertanyaan bisnis, proses cleaning menyeluruh, dan validasi statistik formal membawa pada lima temuan utama berikut:

1. Prepared Food adalah kategori kerugian terbesar secara global.

Dengan total kerugian ekonomi mencapai 17,87 juta USD dari 2018 hingga 2024, kategori ini melampaui semua kompetitornya termasuk Meat & Seafood. Fokus KeduaKali pada segmen ini bukan hanya logis secara operasional, tetapi juga optimal secara dampak.

2. Indonesia berada dalam krisis food waste yang volatil dan tidak tertangani.

Lonjakan 380% dalam satu tahun (2022 ke 2023) dan posisi keempat global dalam rasio limbah per populasi membuktikan bahwa masalah ini sudah melampaui kapasitas manajemen konvensional. Ketidaktersediaan data 2024 mengonfirmasi absennya infrastruktur monitoring yang memadai.

3. Penjualan adalah antidot terkuat untuk food waste.

Korelasi negatif antara quantity_sold dan leftover membuktikan bahwa setiap unit yang berhasil dijual adalah satu unit yang diselamatkan. Model prediksi surplus yang akurat adalah investasi dengan return tertinggi bagi ekosistem KeduaKali.

4. Promosi adalah mekanisme penyelamatan yang terukur dan terbukti secara statistik.

A/B Testing dengan Z-Test proporsi mengkonfirmasi bahwa promosi signifikan secara statistik dalam meningkatkan konversi penjualan (Uji 1) maupun mengurangi sisa makanan (Uji 2) pada tingkat kepercayaan 95%. Dampaknya bervariasi per segmen, namun konsisten positif.

5. Setiap segmen memiliki profil risiko dan musim surplus yang berbeda.

Fine Dining rawan sepanjang tahun dengan volume rendah, Kopitiam berfluktuasi dramatis, Food Stall sensitif terhadap cuaca hujan. Model prediksi yang efektif harus dikalibrasi secara terpisah untuk setiap segmen, bukan menggunakan pendekatan one-size-fits-all.

5.2 Rekomendasi Strategis untuk Platform KeduaKali

Prioritas 1: Model Prediksi Surplus Berbasis LSTM per Segmen

1. Bangun model LSTM terpisah untuk setiap tipe restoran (bukan satu model global).
2. Fitur input utama: data temporal (bulan, hari, IsWeekend), volume penjualan historis, has_promotion, dan feature interaksi promo × tipe restoran.
3. Target: prediksi leftover per slot waktu dengan akurasi cukup untuk memicu notifikasi surplus sebelum makanan benar-benar terbuang.
4. Gunakan rate konversi per segmen dari A/B Testing sebagai baseline kalibrasi threshold.

Prioritas 2: Integrasi Weather API ke Mesin Rekomendasi

1. Integrasikan Weather API real-time sebagai sinyal trigger untuk sistem rekomendasi.
2. Implementasi: saat ramalan hujan sistem secara otomatis menaikkan peringkat rekomendasi produk surplus dari Food Stall kepada konsumen terdekat.
3. Saat prakiraan cerah prioritaskan Kopitiam sebagai source surplus yang perlu didistribusikan.
4. ini adalah keputusan berbasis data empiris dari Pertanyaan Bisnis 5.

Prioritas 3: Dashboard Monitoring & Urgency Framing untuk Mitra Restoran

5. Sajikan visualisasi data tren kerugian ekonomi kepada calon mitra restoran sebagai framing urgensi bergabung.
6. Tampilkan perbandingan Before vs After promosi (seperti di Pertanyaan 7) sebagai bukti ROI yang konkret.
7. Fitur ini memperpendek siklus akuisisi mitra dengan mengubah data menjadi argumen bisnis yang meyakinkan.

5.3 Penutup

Proyek KeduaKali membuktikan bahwa food waste bukan hanya masalah yang bisa diidentifikasi secara statistik, tetapi juga masalah yang bisa diatasi secara sistematis dengan kombinasi data yang tepat, model yang akurat, dan mekanisme promosi yang terbukti.

Setiap insight dalam laporan ini bukan sekadar temuan akademik, melainkan cetak biru fungsional untuk fitur-fitur yang akan dibangun dalam platform KeduaKali. Dari prediksi surplus berbasis LSTM, integrasi cuaca real-time, hingga Smart Promotion yang didukung bukti statistik, semuanya berakar dari data.

“Food waste is a solvable problem. We just need the right data, the right model, and the right platform.”

— Tim KeduaKali, Coding Camp 2026 powered by DBS Foundation